容器网络性能优化之旅

刘梦馨@Kube-OVN

什么是Kube-OVN




- 一个 Kubernetes CNI 的实现
- 一个为 Kubernetes 设计的 SDN
- 一个 CNCF Sandbox 项目

什么是 OVN

- •一个 OVS 的控制平面
- OVN to OVS ≈ Kubernetes to Docker

- Overlay 网络,UDP进行封装
- •逻辑路由器,逻辑交换机
- ACL, QoS
- 负载均衡器,网关,DNS,DHCP

OpenFlows



一年前的测试




基本方法



• 结果: 什么都没调出来

基本方法




- 目标:不能和其他网络插 件差太多
- 结果:某些场景下性能比宿主机网络还要好点
- 一些结论和方法可适用于 其他网络插件

测试基准和方法

- 使用固定物理机物理机和虚拟机,只运行性能测试容器避免感干扰
- cpu 性能模式,避免延迟测试浮动
 - cpupower frequency-set -g performance
- qperf 收集小包不同大小包的 udp_lat-tcp_bw/udp_bw/tcp_lat/udp_lat
 - qperf 10.16.0.4 -ub -oo msg_size:1 -vu tcp_lat tcp_bw udp_lat udp_bw
- 火焰图收集 CPU Profile 信息
 - perf record -F 999 -a -g -p \$(pidof qperf)

1byte	tcp_lat (us)	udp_lat (us)	tcp_bw (Mb/s)	udp_bw(Mb/s)
host	13.1	12.4	28.2	6.02
container	25.7	22.9	27.1	1.59

第一轮Profile



OVS NAT action花费 30%CPU


第一轮优化

- OVN 内部逻辑只要用 LB 所有流量都会过 ct 和 ovs_clone
- 删除 OVN LB 逻辑,改回用 kube-proxy 实现服务发现
 - ovn-nbctl Is-lb-del ovn-defaul
 - 更改ovn 流表编排非 svc 流量不过 ct 和 ovs_clone

	tcp_lat (us)	udp_lat (us)	tcp_bw (Mb/s)	udp_bw(Mb/s)
host	13.1	12.4	28.2	6.02
container	25.7	22.9	27.1	1.59
without lb	18.5	16.5	27.5	2.8

• 延迟降低 30%

第二轮 Profile



发包过程中为什么 会有软中断和 recieve 操作?

veth处理消耗 5% CPU


第二轮优化

• 使用 internal-port 代替 veth

	tcp_lat (us)	udp_lat (us)	tcp_bw (Mb/s)	udp_bw(Mb/s)
host	13.1	12.4	28.2	6.02
container	25.7	22.9	27.1	1.59
without lb	18.5	16.5	27.5	2.8
internal-port	18	16.7	27.4	3.13

• 延迟无明显变化

第三轮 Profile



新增 neigh_resolve_output 占据 6% CPU 消耗

nf_hook_slow 27% CPU 消耗

iptables/nftables/ipvs/conntra ck 均会注册 hook

容器/宿主机 * 2 nf_hook_slow in/out *2 nf_hook_slow


第三轮优化

- 编写 netfilter 模块提前绕行容器网络流量和隧道流量
 - NF_STOP 提前终止 netfilter 执行
 - https://github.com/kubeovn/kube-ovn/tree/master/fastpath

	tcp_lat (us)	udp_lat (us)	tcp_bw (Mb/s)	udp_bw(Mb/s)
host	13.1	12.4	28.2	6.02
container	25.7	22.9	27.1	1.59
without Ib	18.5	16.5	27.5	2.8
internal-port	18	16.7	27.4	3.13
netfilter	15.1	13.5	27.5	4.82

• 延迟降低 20%

第四轮 Profile




ovs_flow_tbl_lookup 占据 10% CPU 消耗

第四轮优化

- 重新编译 ovs 内核模块,增加 x86 指令优化
 - ./configure --with-linux=/lib/modules/\$(uname -r)/build CFLAGS="-g -O2 -mpopcnt msse4.2"

	tcp_lat (us)	udp_lat (us)	tcp_bw (Mb/s)	udp_bw(Mb/s)
host	13.1	12.4	28.2	6.02
container	25.7	22.9	27.1	1.59
without lb	18.5	16.5	27.5	2.8
internal-port	18	16.7	27.4	3.13
netfilter	15.1	13.5	27.5	4.82
intel optimize	13.9	12.9	27.6	5.57

• 延迟降低 5%



性能问题解决了



1K数据包吞吐量优化

 qperf -t 30 10.16.0.4 -ub -oo msg_size:1K -vu tcp_lat tcp_bw udp_lat udp_bw

perf record -F 999 -a -g -p \$(pidof qperf)

	tcp_lat (us)	udp_lat (us)	tcp_bw (Gb/s)	udp_bw(Gb/s)
host	28.4	27.2	9.41	5.81
container	28.2	28.2	4.94	5.13

1K数据包吞吐量优化

```
port.tx_dropped_IIIK_down. 0
[root@da-c3-small-x86-02 165]# ethtool -S eno2 |grep droppe rx_dropped: 5732843
tx_dropped: 0
port.rx_dropped: 0
port.tx_dropped_link_down: 0
[root@da-c3-small-x86-02 165]#
```

• ethtool -G eno2 rx 4096

	tcp_lat (us)	udp_lat (us)	tcp_bw (Gb/s)	udp_bw(Gb/s)
host	28.4	27.2	9.41	5.81
container	28.2	28.2	4.94	5.13
4096 rx	28.2	28.3	8.39	5.28

性能问题又解决了



虚拟机吞吐量优化

iperf Done.

```
[root@liumengxin-ovn1-192 ~]# iperf3 -c 192.168.16.45
Connecting to host 192.168.16.45, port 5201
  4] local 192.168.16.44 port 54198 connected to 192.168.16.45 port 5201
                                                   Retr Cwnd
 IDl Interval
                       Transfer
                                    Bandwidth
       0.00-1.00
                  sec 1.43 GBvtes 12.2 Gbits/sec
                                                         3.01 MBytes
                  sec 2.04 GBytes 17.6 Gbits/sec
                                                        3.01 MBytes
       1.00-2.00
       2.00-3.00
                  sec 2.34 GBytes 20.1 Gbits/sec
                                                        3.01 MBytes
       3.00-4.00
                 sec 1.96 GBytes 16.9 Gbits/sec
                                                        3.01 MBytes
      4.00-5.00 sec 2.06 GBytes 17.7 Gbits/sec
                                                        3.01 MBytes
       5.00-6.00 sec 1.75 GBytes 15.1 Gbits/sec
                                                        3.01 MBvtes
      6.00-7.00 sec 1.81 GBytes 15.5 Gbits/sec
                                                        3.01 MBytes
      7.00-8.00 sec 1.91 GBytes 16.4 Gbits/sec
                                                        3.01 MBytes
      8.00-9.00
                  sec 1.96 GBytes 16.8 Gbits/sec
                                                        3.01 MBytes
       9.00-10.00 sec 2.01 GBytes 17.3 Gbits/sec
                                                        3.01 MBytes
                       Transfer
 ID] Interval
                                                   Retr
      0.00-10.00 sec 19.3 GBytes 16.5 Gbits/sec
      0.00-10.00 sec 19.3 GBytes 16.5 Gbits/sec
                                                                   receiver
iperf Done.
[root@liumengxin-ovn1-192 \sim]# docker exec -it d1c4dc1858ed sh
  4] local 10.16.0.8 port 52462 connected to 10.16.0.14 port 5201
 ID] Interval
                       Transfer
                                    Bandwidth
                                                   Retr Cwnd
       0.00-1.00
                        160 MBytes 1.34 Gbits/sec
                                                    0 1.55 MBytes
       1.00-2.00
                        200 MBytes 1.68 Gbits/sec
                                                     0 1.55 MBytes
       2.00-3.00
                        216 MBytes 1.81 Gbits/sec
                                                     0 1.55 MBytes
       3.00-4.00
                        181 MBytes 1.52 Gbits/sec
                                                        1.55 MBytes
       4.00-5.00
                        176 MBytes 1.48 Gbits/sec
                                                        1.55 MBytes
       5.00-6.00
                                                     0 1.55 MBytes
                        202 MBytes 1.70 Gbits/sec
      6.00-7.00
                        185 MBytes 1.55 Gbits/sec
                                                        1.55 MBytes
      7.00-8.00
                        200 MBytes 1.68 Gbits/sec
                                                        1.55 MBytes
       8.00-9.00
                        209 MBytes 1.75 Gbits/sec
                                                        1.55 MBytes
       9.00-10.00 sec
                        181 MBytes 1.52 Gbits/sec
                                                        1.55 MBytes
 ID] Interval
                       Transfer
                                                   Retr
       0.00-10.00 sec 1.87 GBytes 1.60 Gbits/sec
                                                                   sender
       0.00-10.00 sec 1.86 GBytes 1.60 Gbits/sec
                                                                   receiver
```

virtio_net 类型虚拟网卡无法 调整 rx queue

Profile 发现 client 端存在瓶 颈大量 tcp_push 怀疑无法 使用 tso 等卸载能力

Geneve 封装为 UDP 虚拟机 CPU 能力不足情况下差距明显

虚拟机吞吐量优化

- 使用 STT 封装代替 Geneve 封装
 - ovs-vsctl set open . external_ids:ovn-encap-type=stt
 - stt 使用 tcp 格式 header 可利用网卡 tso 能力
 - 1.6Gbit/s -> 11.7 Gbit/s
 - profile 发现 STT 依赖 netfilter 实现,带回 20% cpu 开销

```
iperf3 -c 10.16.0.14
Connecting to host 10.16.0.14, port 5201
  4] local 10.16.0.8 port 55140 connected to 10.16.0.14 port 5201
 ID| Interval
                       Transfer
                                   Bandwidth
                                                  Retr Cwnd
       0.00-1.00
                  sec 1.26 GBytes 10.8 Gbits/sec
                                                        2.51 MBytes
       1.00-2.00
                sec 1.26 GBytes 10.9 Gbits/sec
                                                   0 3.02 MBytes
      2.00-3.00
                  sec 1.60 GBytes 13.7 Gbits/sec
                                                   0 3.02 MBytes
      3.00-4.00
                  sec 1.52 GBytes 13.1 Gbits/sec
                                                   0 3.02 MBytes
      4.00-5.00 sec 1.36 GBytes 11.6 Gbits/sec
                                                   0 3.02 MBytes
      5.00-6.00 sec 1.32 GBytes 11.4 Gbits/sec
                                                   0 3.02 MBytes
      6.00-7.00 sec 1.16 GBytes 9.97 Gbits/sec
                                                   0 3.02 MBytes
      7.00-8.00
                sec 1.17 GBytes 10.1 Gbits/sec
                                                   0 3.02 MBytes
      8.00-9.00
                  sec 1.47 GBytes 12.7 Gbits/sec
                                                        3.02 MBytes
       9.00-10.00
                      1.47 GBytes
                                  12.6 Gbits/sec
                                                        3.02 MBytes
                  sec
 ID | Interval
                       Transfer
                                   Bandwidth
                                                   etr
       0.00-10.00
                  sec 13.6 GBytes
                                   11.7 Gbits/sec
                                                                 sender
       0.00-10.00
                  sec 13.6 GBytes
                                   11.7 Gbits/sec
                                                                 receiver
```

虚拟机吞吐量优化

- STT 模块优化
 - STT netfilter hook 挂载点前移
 - Netfilter OUTPUT 跳过 STT 端口流量处理
 - 11.7Gbit/s -> 14.0 Gbit/s

```
iperf3 -c 10.16.0.14
Connecting to host 10.16.0.14, port 5201
  4] local 10.16.0.8 port 57892 connected to 10.16.0.14 port 5201
  ID | Interval
                        Transfer
                                    Bandwidth
                                                    Retr Cwnd
                   sec 1.73 GBytes 14.8 Gbits/sec
       0.00-1.00
                                                          2.49 MBytes
       1.00-2.00
                   sec 1.69 GBytes 14.5 Gbits/sec
                                                          2.94 MBytes
       2.00-3.00
                   sec 1.35 GBytes 11.6 Gbits/sec
                                                          3.00 MBytes
       3.00-4.00
                   sec 1.93 GBytes
                                    16.7 Gbits/sec
                                                          3.00 MBytes
       4.00-5.00
                                                          3.00 MBytes
                       1.86 GBytes
                                    16.0 Gbits/sec
                   sec
       5.00-6.00
  4]
                       1.27 GBytes
                                    10.9 Gbits/sec
                                                          3.00 MBytes
  4]
                                    14.2 Gbits/sec
       6.00-7.00
                       1.65 GBytes
                                                          3.00 MBytes
                   sec
                        1.75 GBytes
       7.00-8.00
                                    15.0 Gbits/sec
                                                          3.00 MBytes
                                                          3.00 MBytes
       8.00-9.00
                        1.25 GBytes
                                    10.7 Gbits/sec
       9.00-10.00
                       1.87 GBytes 16.0 Gbits/sec
                                                          3.00 MBytes
                                    Bandwidth
                                                    Retr
 ID] Interval
                        Transfer
       0.00-10.00
                   sec 16.4 GBytes
                                     14.0 Gbits/sec
                                                                    sender
       0.00-10.00
                        16.3 GBytes
                                     14.0 Gbits/sec
                                                                    receiver
```

经验总结

- · 经过优化 Kube-OVN 可以达到接近宿主机水平性能
- 其他容器网络可以遵循类似的方法进行优化
- 优化建议
 - 慎用 OVN LB, 避免延迟开销
 - 使用 STT 封装代替 Geneve/Vxlan 获取更好吞吐量
 - 性能关键链路避开 Netfilter
 - 利用指令集相关优化进行编译
 - 调整 rx queue 长度
 - 先 profile 后优化
 - 不要畏惧改内核(20%+性能提升)

未来的方向

- OVS-DPDK? eBPF?
- •智能网卡
 - ct, openflow, tunnel, gos offload
 - arm core: ovs/ovn offload
- UDP offload
 - https://developers.redhat.com/articles/2021/11/05/improve-udpperformance-rhel-85#
- New CT Solution
 - https://www.youtube.com/watch?v=LlxyZaDwKAc&list=PLaJlRaxltwARDGAUp7lXviOgOhcRxSU-&index=31
 - https://www.openvswitch.org/support/ovscon2021/slides/a_new_solution_conntrack.pdf

Thanks